Clase 4 de Mayo

Mariano Dominguez

April 24, 2018

Análisis exploratorio y curación de datos

- Mariano Dominguez @ IATE-OAC-UNC & CONICET
- Edgardo Hames @ Bitlogic
- Gabriel Miretti @ Bitlogic

Figure 1: Diplodatos @ FaMAF

Paradigmas cientificos clasicos:

Siglos atras la ciencia era **empirica**, describiendo los procesos naturales.

Figure 2: Galileo observando con un telescopio

luego se desarrollaron modelos **teoricos** matematicos, generalizaciones

$$\nabla \cdot \mathbf{E} = \frac{\rho_v}{\varepsilon} \qquad \text{(Gauss' Law)}$$

$$\nabla \cdot \mathbf{H} = 0 \qquad \text{(Gauss' Law for Magnetism)}$$

$$\nabla \times \mathbf{E} = -\mu \frac{\partial \mathbf{H}}{\partial t} \qquad \text{(Faraday's Law)}$$

$$\nabla \times \mathbf{H} = \mathbf{J} + \varepsilon \frac{\partial \mathbf{E}}{\partial t} \qquad \text{(Ampere's Law)}$$

Figure 3: Newton, Maxwell, Einstein, Dirac eqs

Astronomia (u otra ciencia) Computacional

En las ultimas decadas se han simulando fenomenos complejos.

Figure 4: Simulacion cosmologica LCDM

El cuarto paradigma en ciencia:

Hoy en dia la exploracion de datos (eScience) unifica la teoria, los experimentos y las simulaciones.

– Datos capturados por instrumentos o generados por una simulacion. – Procesados por complejos pipelines de software. – Cientifico analiza bases de datos utilizando tecnicas estadisticas.

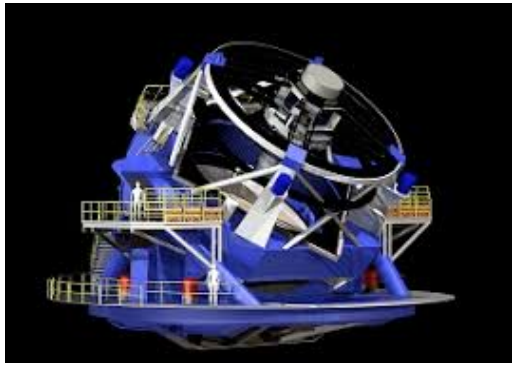

Figure 5: LSST telescopio y camara

http://www.astro.caltech.edu/~george/aybi199/4th_paradigm_book_complete_lr.pdf

Por que (no) R? es FLOSS!

Introduccion al lenguaje estadistico R http://r-project.org y CRAN http://cran.r-project.org/ : R consiste en una colleccion de software con una importante variedad de paquetes para analisis de datos, matematica aplicada, estadistica , graficos y diferentes utilidades. Los paquetes extras en CRAN son suministrados por individuos o comunidades de expertos en biologia, economia, geologia y otros campos (ver https://www.jstatsoft.org/index).

Existe una linda IDE: RStudio https://www.rstudio.com/ y una muy buena biblioteca para graficos ggplot2 (now ggviz). Tambien existen diversas galeria de graficos en R y recientemente se ha establecido el consorcio R: https://www.r-consortium.org/ (Microsoft compro Revolution, ver tambien h2o).

Se ha realizado un considerable esfuerzo para conectar R con otros programas, lenguajes y sistemas estadisticos. Scripts en R pueden correr facilmente desde la consola, pero mas esfuerzo es necesario para correr programas en otros lenguajes. R se conecta con C, C++, FORTRAN, JaVa, JavaScript, Matlab, Python, Perl, XLisp y Ruby.

Estadistica con R

Una nocion basica es la de una muestra aleatoria.

E R es posible simular facilmente esta situacion con la funcion **sample**. Si por ejemplo quiero elegir cinco numero aleatorios entre 1 y 40, escribo:

```
## [1] 19 30 23 16 32
```

Muestrear con reeemplazo es adecuado para modelar monedas o dados. Por ejemplo para simular arrojar diez monedas podemos escribir:

```
##  [1] "H" "H" "T" "T" "T" "H" "H" "H" "H" "T"
```

Tambien se puede simular datos con diferentes probabilidades de cada resultado, (por ejemplo tener una tasa de exitos del 90%) utilizando el argumento prob in sample:

```
##  [1] "fail" "succ" "succ" "succ" "succ" "succ" "succ" "s
```

Distribuciones discretas en R:

cuando las variables solo pueden tomar solamente valores finitos, es preferible dibujar un digrama de alfileres (pin), aqui podemos observar la distribucion binomial con n=50 y p=0.33.

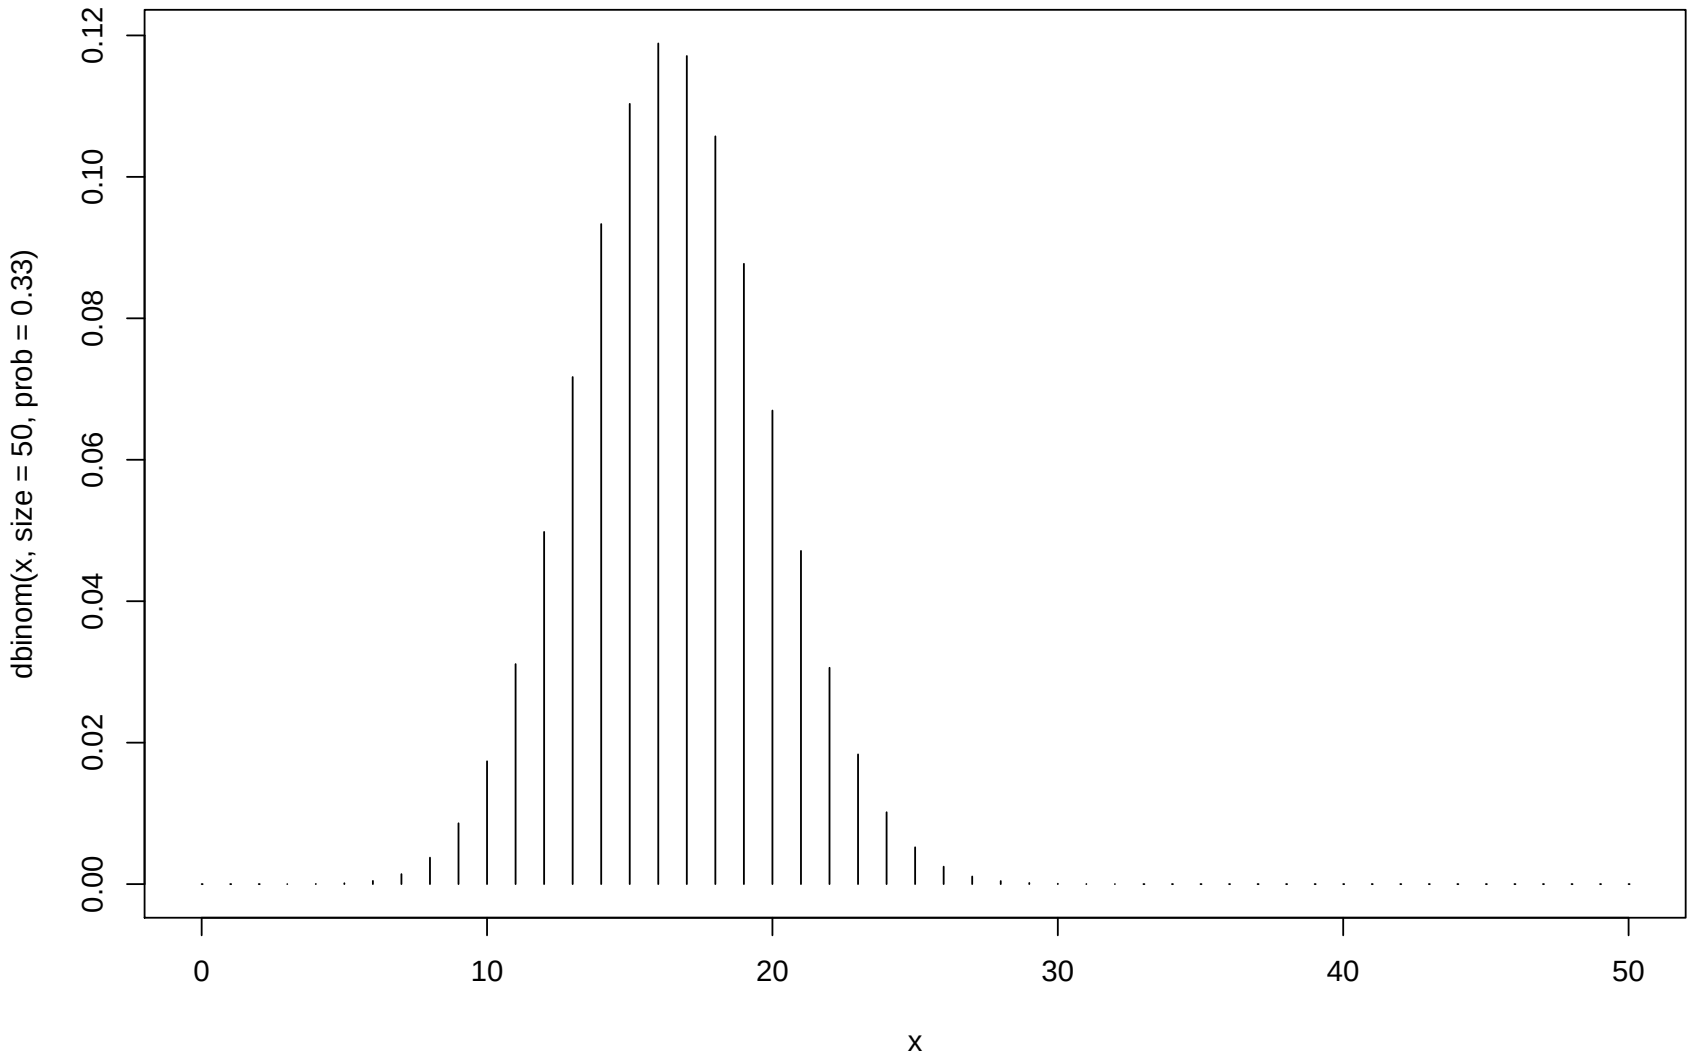

Numeros Aleatorios:

En general suena contradictorio generar numeros aleatorios en una computadora dado que se supone que sus resultados son predecibles y reproducibles. Lo que en realidad es posible es generar secuencias de numeros pseudo aleatorios, que para todos los efectos practicos se comportan como si fueran aleatorios. Ver sobre LCGs, http://www.aaronschlegel.com/series/random-number-generation/

En estadistica se utilizan para crear conjuntos de datos simulados para estudiar los efectos de los algoritmos. El uso de funciones que generan numeros aleatorios es simple, por ejemplo numeros que siguen una distribucion normal:

```
## [1] -0.03165378
```

```
## [1] 1.038076
```

```
##           0%          25%          50%          75%
## -3.202448027 -0.600522968 -0.003746685  0.637669106  2.1
```

Distribution uniforme

El generador basico en R es runif, cuya entrada es el numero de valores a ser generados.

```
##  [1] 2.877472 4.586499 3.689714 2.070500 2.072814 4.9045
##  [8] 3.582958 3.727030 4.925881
```

Veamos como funciona:

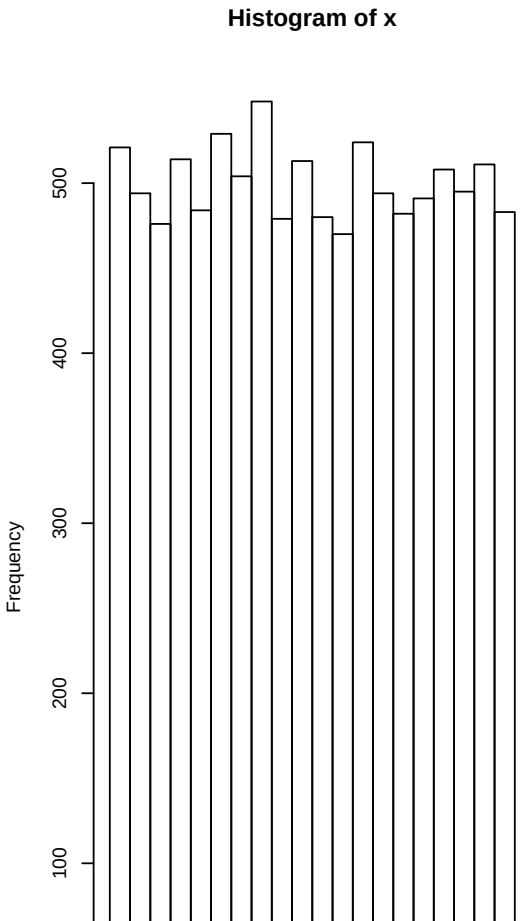

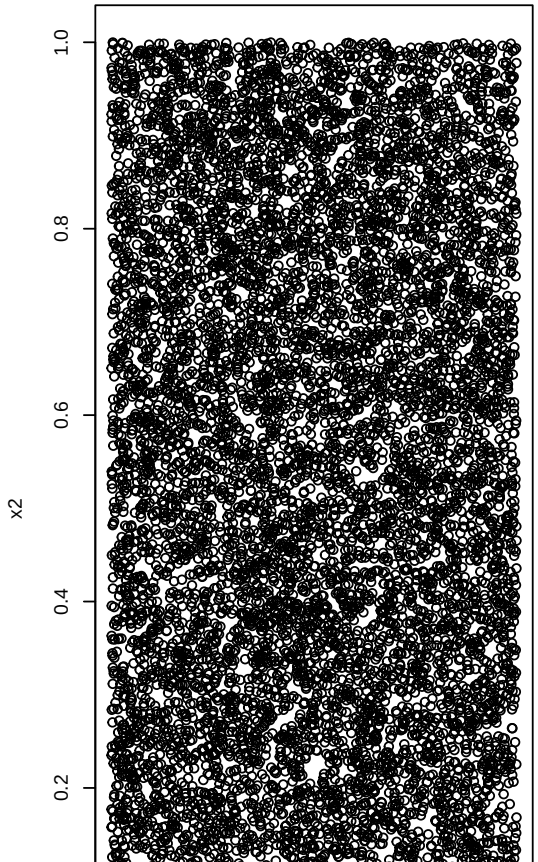

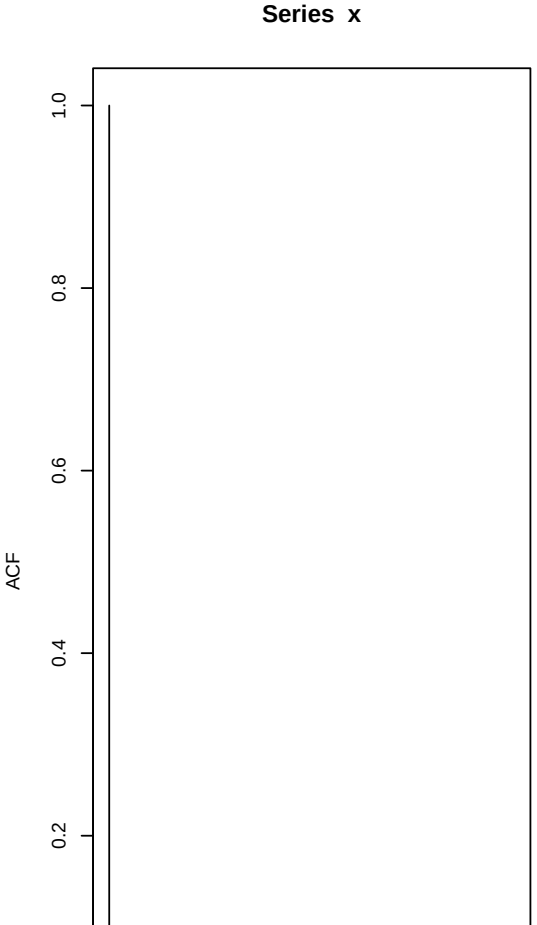

Guardando las semillas.

runif no implica aleatoridad per se. runif(Nsim) es calcular una secuencia deterministica basada en un numero aleatorio inicial (semilla).

```
set.seed(1)
runif(5)
```

```
## [1] 0.2655087 0.3721239 0.5728534 0.9082078 0.2016819
```

```
set.seed(1)
runif(5)
```

```
## [1] 0.2655087 0.3721239 0.5728534 0.9082078 0.2016819
```

```
set.seed(2)
runif(5)
```

```
## [1] 0.1848823 0.7023740 0.5733263 0.1680519 0.9438393
```

La transformacion Inversa del CDF:

Existe una transformacion simple, que nos permite transformar cualquier variable aleatoria en una uniforme y mas importante viceversa.

Por ejemplo si x esta dada por una densidad de probabilidad f y una CDF F , entonces vale la relacion: $F(x) = \int_{-\infty}^{x} f(t)\delta t$ y si elegmimos $U = F(X)$, con U una variable aleatoria distribuida uniformemente.

Ejemplo: Si $X \propto exp$, entonces $F(x) = 1 - e^{-x}$. Resolviendo para x en $u = 1 - e^{-x}$ nos da $x = -log(1 - u)$. Por lo tanto si u es uniforme, entonces $X \propto exp$

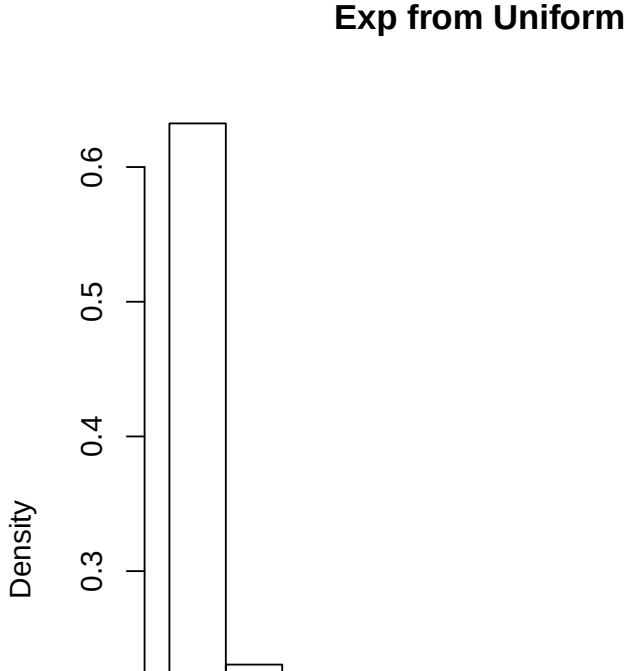

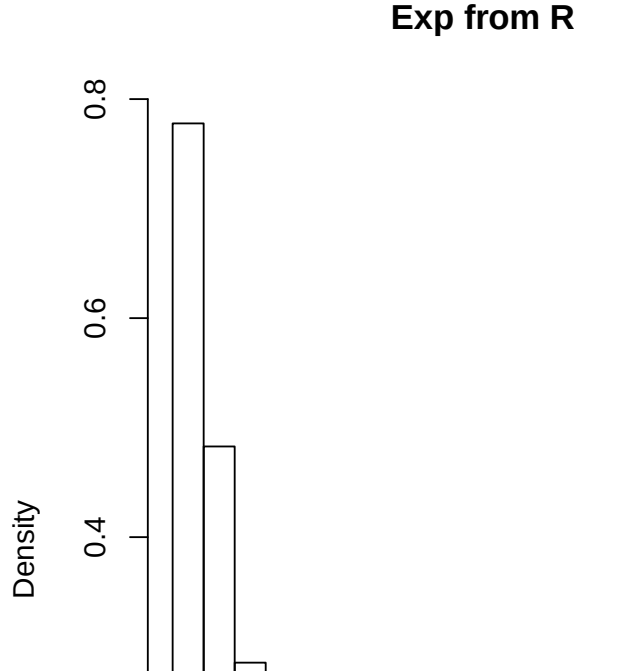

Submuestras

Los comandos subset(), which() and ifelse() son probablemente los mas utilizados en R. Una manera de filtrar elementos de un vector es utilizar la funcion subset().

```
# create a vector
x <- c(5,4:8,12)
x
```

```
## [1]  5  4  5  6  7  8 12
```

```
y <- subset(x, x < 6)
y
```

```
## [1] 5 4 5
```

Utilizando which()

identifica la posicion del vector donde se cumple (is TRUE) la condicion: Vea el siguiente ejemplo de como utilizarla:

```
# create a vector
z <- c(6:10, 12, -3)
z
```

```
## [1]  6  7  8  9 10 12 -3
```

```
which(z > 8)
```

```
## [1] 4 5 6
```

Utilizando ifelse

el comnado ifelse tiene dos opciones para ejecutar. Si la condicion es TRUE se ejecuta la primera, si la condicion es FALSE se ejecuta la segunda. La sintaxis es ifelse(condition, opcion1, opcion2). Un ejemplo a continuacion.

```
# create a vector
x <- c(-2, 5:10, 15)
x
```

```
## [1] -2  5  6  7  8  9 10 15
```

```
# if values are < 7 will code those 1, else will become 0
ifelse(x < 7, 1, 0)
```

```
## [1] 1 1 1 0 0 0 0 0
```

```
# also you can do this
ifelse(x < 7, 1, x)
```

Code the Matrix 1:

Creamos una matriz x con numeros provenientes de una funcion normal. y llamamos a sus elementos con x[fila,columna].

```
# matrix with 12 random numbers in 4 rows
x <- matrix(rnorm(12), nrow=4)
x
```

```
##             [,1]       [,2]       [,3]
## [1,]  1.2891946 -1.9527802 -0.0692199
## [2,]  0.5955489 -0.3774369  0.1197222
## [3,]  1.1870120  0.4915441  0.9573790
## [4,] -0.1418306  0.1169809 -0.3900849
```

```
# find the number in 3rd row and 2nd column
x[3,2]
```

```
## [1] 0.4915441
```

Code the Matrix 2:

tambien es posible referirse a una columna o fila u obtener las dimensiones.

```
# show second columns
x[,2]
```

```
## [1] -1.9527802 -0.3774369  0.4915441  0.1169809
```

```
# show forth row
x[4,]
```

```
## [1] -0.1418306  0.1169809 -0.3900849
```

```
# find number or columns and rows in matrix
dim(x)
```

```
## [1] 4 3
```

Utilizando lazos en R:

Cada vez que alguna operacion debe ser repetida un lazo resulta util. De acuerdo el manual de R, entre los comandos basicos de control de flujo, las construcciones para lazos son: fort, while y repeat, con las clausulas adicionales break y next.

Un ejemplo de un lazo simple:

```
## [1] "This loop calculates the square of the first 10 ele

## [1] 3.326407
## [1] 0.9550669
## [1] 0.4375794
## [1] 0.007272402
## [1] 0.5649414
## [1] 0.1361074
## [1] 0.01092893
## [1] 0.1821844
## [1] 0.443898
## [1] 0.3556551
```

Lazos anidados

Supongamos que queremos manipular una matriz poniendo sus elementos con valores especificos:

```
##       [,1] [,2] [,3] [,4] [,5] [,6] [,7] [,8] [,9] [,10]
##  [1,]    1    2    3    4    5    6    7    8    9    10
##  [2,]    2    4    6    8   10   12   14   16   18    20
##  [3,]    3    6    9   12   15   18   21   24   27    30
##  [4,]    4    8   12   16   20   24   28   32   36    40
##  [5,]    5   10   15   20   25   30   35   40   45    50
##  [6,]    6   12   18   24   30   36   42   48   54    60
##  [7,]    7   14   21   28   35   42   49   56   63    70
##  [8,]    8   16   24   32   40   48   56   64   72    80
##  [9,]    9   18   27   36   45   54   63   72   81    90
## [10,]   10   20   30   40   50   60   70   80   90   100
```

Vectorizacion 1:

es la operacion de convertir repetidas operaciones en numeros (escalares) en operaciones en vectores o matrices. Muchos lazos pueden hacerse implicitos con vectorizacion.
el ejemplo mas elemental es la adicion de dos vectores v1 y v2 en un vector v3, lo que puede hacerse elemento por elemento con un lazo:

```
n=100
v1 <- rnorm(n)
v2 <- rnorm(n)
v3 <- 0
#
for (i in 1:n)
{
v3[i] <-v1[i] + v2[i]
}
```

Vectorizacion 2:

o utilizando la forma vectorizada:

```
v3 = v1 + v2
```

lo que permite utilizar eficientemente rutinas muy eficientes de algebra lineal (BLAS)
Comparemos el tiempo de ejecucion entre ambas soluciones:

```
m=10; n=10;
mymat<-replicate(m, rnorm(n)) # create matrix of normal ra
mydframe=data.frame(mymat) # transform into data frame
# measure loop execution
system.time(
for (i in 1:m) {
for (j in 1:n) {
mydframe[i,j]<-mydframe[i,j] + 10*sin(0.75*pi)
}
}
)
```

La familia de instrucciones apply.

Esta compuesta de funciones intrinsecamente vectorizada y esta compuesta de funciones ([s,l,m,r, t,v]apply) para manipular datos en forma de matrices en una forma repetitiva, evitando el uso explicito de lazos. Las primeras tres son las mas utilizadas:

1. apply permite aplicar una funcion a filas (primer indice) o columnas (segundo indice) de una matriz.
2. lapply permite aplicar una dada funcion a cada elemento de una lista.
3. sapply igual que la anterior, pero se obtiene un vector en lugar de una lista.

```r
#### elementary example of apply function
# define matrix mymat by replicating the sequence 1:5 for
mymat<-matrix(rep(seq(5), 4), ncol = 5)
# mymat sum on rows
apply(mymat, 1, sum)
```

```
## [1] 15 15 15 15
```

```r
# mymat sum on columns
apply(mymat, 2, sum)
```

```
## [1] 10 11 12 13 14
```

```r
# produce a summary column wise (for each column)
apply(mymat, 2, function(x, y) summary(mymat))
```

```
##       [,1]                [,2]                [,3]
##  [1,] "Min.   :1.00  " "Min.   :1.00  " "Min.   :1.00  "
##  [2,] "1st Qu.:1.75  " "1st Qu.:1.75  " "1st Qu.:1.75  "
##  [3,] "Median :2.50  " "Median :2.50  " "Median :2.50  "
```

Importando y exportando datos.

Los datos en R pueden guardarse como archivos .Rdata con la funcion save. Que luego pueden leerse en R con load.

```
a <- 1:10
save(a, file = "Data.Rdata")
rm(a)
load("Data.Rdata")
print(a)
```

```
##  [1]  1  2  3  4  5  6  7  8  9 10
```

Presentando los Data Frames:

El siguiente ejemplo crea un dataframe a y lo guarda como un archivo CSV con write.cvs. Luego el dataframe is cargado desde el archivo a una variable b con read.cvs.

```
var1 <- 1:5
var2 <- (1:5) / 10
var3 <- c("Diplo", "Datos", "en", "FaMAF", "@UNC")
a <- data.frame(var1, var2, var3)
names(a) <- c("VariableInt", "VariableReal", "VariableChar"
write.csv(a, "Data.csv", row.names = FALSE)
 #rm(a)
b <- read.csv("Data.csv")
print(b)
```

```
##   VariableInt VariableReal VariableChar
## 1           1           0.1        Diplo
## 2           2           0.2        Datos
## 3           3           0.3           en
```

Creando un Data Frame

Un data frame es similar a una matriz, pero puede contener elementos numericos o texto. La funcion que se utiliza para crear data frames es dataframe() por ej:

```
# create a data frame
hospital <- c("Cordoba", "Buenos Aires")
pacientes <- c(150, 350)
df <- data.frame(hospital, pacientes)
df
```

```
##       hospital pacientes
## 1      Cordoba        150
## 2 Buenos Aires        350
```

```
# structure
str(df)
```

```
## 'data.frame':    2 obs. of  2 variables:
##  $ hospital : Factor w/ 2 levels "Buenos Aires",..: 2 1
```

Read Write Table

La funcion write.table guarda el contenido de un objeto en un archivo. El objeto es tıpicamente un marco de datos ('data.frame'), pero puede ser cualquier otro tipo de objeto (vector, matriz,. . .).

La funcion read.table crea un marco de datos ('data frame') y constituye la manera mas usual de leer datos en forma tabular.

```
misdatos <- read.table("data.dat")
misdatos$hospital
```

```
## [1] Cordoba      Buenos Aires
## Levels: Buenos Aires Cordoba
```

```
misdatos["hospital"]
```

```
##       hospital
## 1      Cordoba
## 2 Buenos Aires
```

cada variable recibira por defecto el nombre V1, V2,... y puede ser accedida individualmente escribiendo misdatos$V1$, misdatos$V2$,... , o escribiendo misdatos["V1"], misdatos["V2"],... , o, tambien escribiendo misdatos[,1], misdatos[,2], .. etc

Existen varias opciones con valores por defecto (aquellos usados por R si son omitidos por el usuario). Para solicitar ayuda utilizar ?

```
?read.table
```

Para mas ejemplos de uso de R puede consultarse https://www.computerworld.com/article/2497464/business-intelligence/top-r-language-resources-to-improve-your-data-skills.html en particular es muy recomendable el paquete http://swirlstats.com/

Para extender el manejo de R ver http://adv-r.had.co.nz/ y como construir paquetes http://r-pkgs.had.co.nz/ y por supuesto <www.r-graph-gallery.com>

coffe & mate breack?

Algunos Datasets intrinsecos:

iris dataset

```
## 'data.frame':    150 obs. of  5 variables:
##  $ Sepal.Length: num  5.1 4.9 4.7 4.6 5 5.4 4.6 5 4.4 4.
##  $ Sepal.Width : num  3.5 3 3.2 3.1 3.6 3.9 3.4 3.4 2.9
##  $ Petal.Length: num  1.4 1.4 1.3 1.5 1.4 1.7 1.4 1.5 1.
##  $ Petal.Width : num  0.2 0.2 0.2 0.2 0.2 0.4 0.3 0.2 0.
##  $ Species     : Factor w/ 3 levels "setosa","versicolor
```

bodyfat dataset, brief excursion to install.packages("") details:

```
## Loading required package: parallel

## Loading required package: stabs

## This is mboost 2.8-1. See 'package?mboost' and 'news(pac
## for a complete list of changes.

## 'data.frame':    71 obs. of  10 variables:
```

Exploracion de Datos 1:

- 1-Checkeando las dimensiones

```
dim(iris)
```

```
## [1] 150   5
```

- 2 nombre de las variable o columnas

```
names(iris)
```

```
## [1] "Sepal.Length" "Sepal.Width"  "Petal.Length" "Petal.
## [5] "Species"
```

- 3 Structura

```
str(iris)
```

```
## 'data.frame':    150 obs. of  5 variables:
##  $ Sepal.Length: num  5.1 4.9 4.7 4.6 5 5.4 4.6 5 4.4 4.
```

Exploracion de Datos 2:

- 4 Attributos

```
attributes(iris)
```

```
## $names
## [1] "Sepal.Length" "Sepal.Width"  "Petal.Length" "Petal.
## [5] "Species"
##
## $row.names
##   [1]   1   2   3   4   5   6   7   8   9  10  11  12  1
##  [18]  18  19  20  21  22  23  24  25  26  27  28  29  3
##  [35]  35  36  37  38  39  40  41  42  43  44  45  46  4
##  [52]  52  53  54  55  56  57  58  59  60  61  62  63  6
##  [69]  69  70  71  72  73  74  75  76  77  78  79  80  8
##  [86]  86  87  88  89  90  91  92  93  94  95  96  97  9
## [103] 103 104 105 106 107 108 109 110 111 112 113 114 11
## [120] 120 121 122 123 124 125 126 127 128 129 130 131 13
## [137] 137 138 139 140 141 142 143 144 145 146 147 148 14
```

Exploracion de Datos 3:

- 5 Veamos las primeras 5 filas

```
iris[1:5,]
```

```
##   Sepal.Length Sepal.Width Petal.Length Petal.Width Spec
## 1          5.1         3.5          1.4         0.2  set
## 2          4.9         3.0          1.4         0.2  set
## 3          4.7         3.2          1.3         0.2  set
## 4          4.6         3.1          1.5         0.2  set
## 5          5.0         3.6          1.4         0.2  set
```

- 6 Veamos los valores de alguna columna

```
iris[1:10, "Sepal.Length"]
```

```
##  [1] 5.1 4.9 4.7 4.6 5.0 5.4 4.6 5.0 4.4 4.9
```

Imputacion de valores NA 1:

```r
# Introduce missing values
set.seed(100)
original<-iris
iris[sample(1:nrow(iris), 40), "Sepal.Length"] <- NA
library(mice)
```

```
## Loading required package: lattice
```

```r
md.pattern(iris)
```

```
##     Sepal.Width Petal.Length Petal.Width Species Sepal.L
## 110           1            1           1       1
##  40           1            1           1       1
##               0            0           0       0
```

Imputacion de valores NA 2:

Esto puede visualizarse como

```
library(VIM)
```

```
## Loading required package: colorspace

## Loading required package: grid

## Loading required package: data.table

## VIM is ready to use.
##  Since version 4.0.0 the GUI is in its own package VIMGU
##
##          Please use the package to use the new (and old

## Suggestions and bug-reports can be submitted at: https:/

##
## Attaching package: 'VIM'
```

Imputacion de valores NA 3:

Para tratar con valores perdidos, el metodo principal es imputar esos valores por ejemplo con la media, mediana, moda o valores cercanos. Otra opcion si se disponen de suficientes datos es ignorar esa medicion (na.action=na.omit)

```
library(Hmisc)
```

```
## Loading required package: survival

## Loading required package: Formula

## Loading required package: ggplot2

##
## Attaching package: 'ggplot2'

## The following object is masked from 'package:mboost':
##
##     %+%
```

Exploracion de variables individuales 1:

- 1 Distribucion de cada variable

```
iris<-original
summary(iris)
```

```
##    Sepal.Length    Sepal.Width     Petal.Length    Petal.
##  Min.   :4.300   Min.   :2.000   Min.   :1.000   Min.
##  1st Qu.:5.100   1st Qu.:2.800   1st Qu.:1.600   1st Qu.
##  Median :5.800   Median :3.000   Median :4.350   Median
##  Mean   :5.843   Mean   :3.057   Mean   :3.758   Mean
##  3rd Qu.:6.400   3rd Qu.:3.300   3rd Qu.:5.100   3rd Qu.
##  Max.   :7.900   Max.   :4.400   Max.   :6.900   Max.
##        Species
##  setosa    :50
##  versicolor:50
##  virginica :50
##
##
##
```

Exploracion de variables individuales 2:

- 2 Frecuencia

```
table(iris$Species)
```

```
##
##     setosa versicolor  virginica
##         50         50         50
```

- 3 Pie chart

```
pie(table(iris$Species))
```

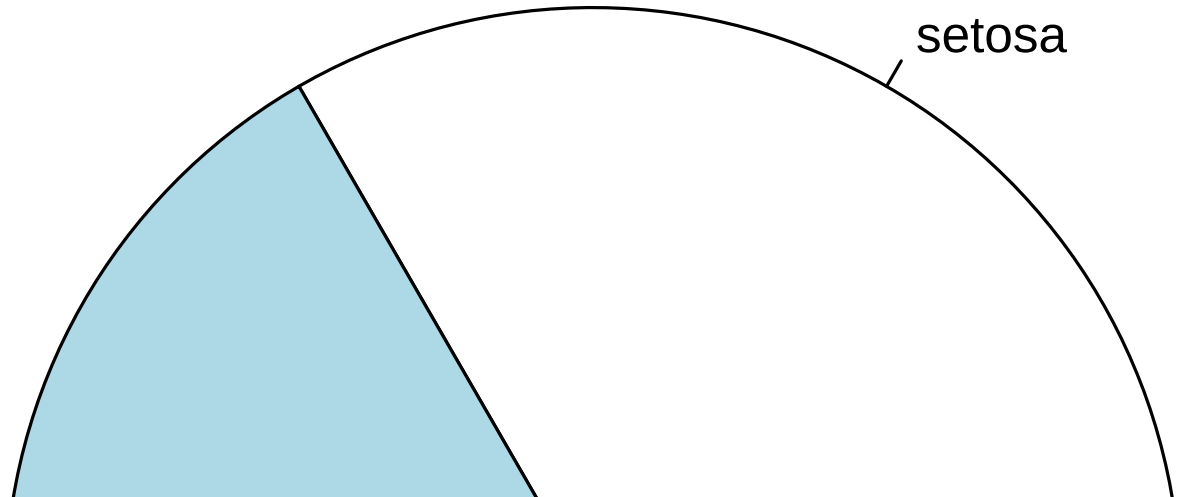

Exploracion de variables individuales 3:

- 4 media y varianza de la Sepal.Length

```
mean(iris$Sepal.Length)
```

```
## [1] 5.843333
```

```
var(iris$Sepal.Length)
```

```
## [1] 0.6856935
```

Exploracion de variables individuales 4:

- 5 Histogramas

```
hist(iris$Sepal.Length)
```

Exploracion de variables individuales 5:

- 6 Densidad

```
plot(density(iris$Sepal.Length))
```

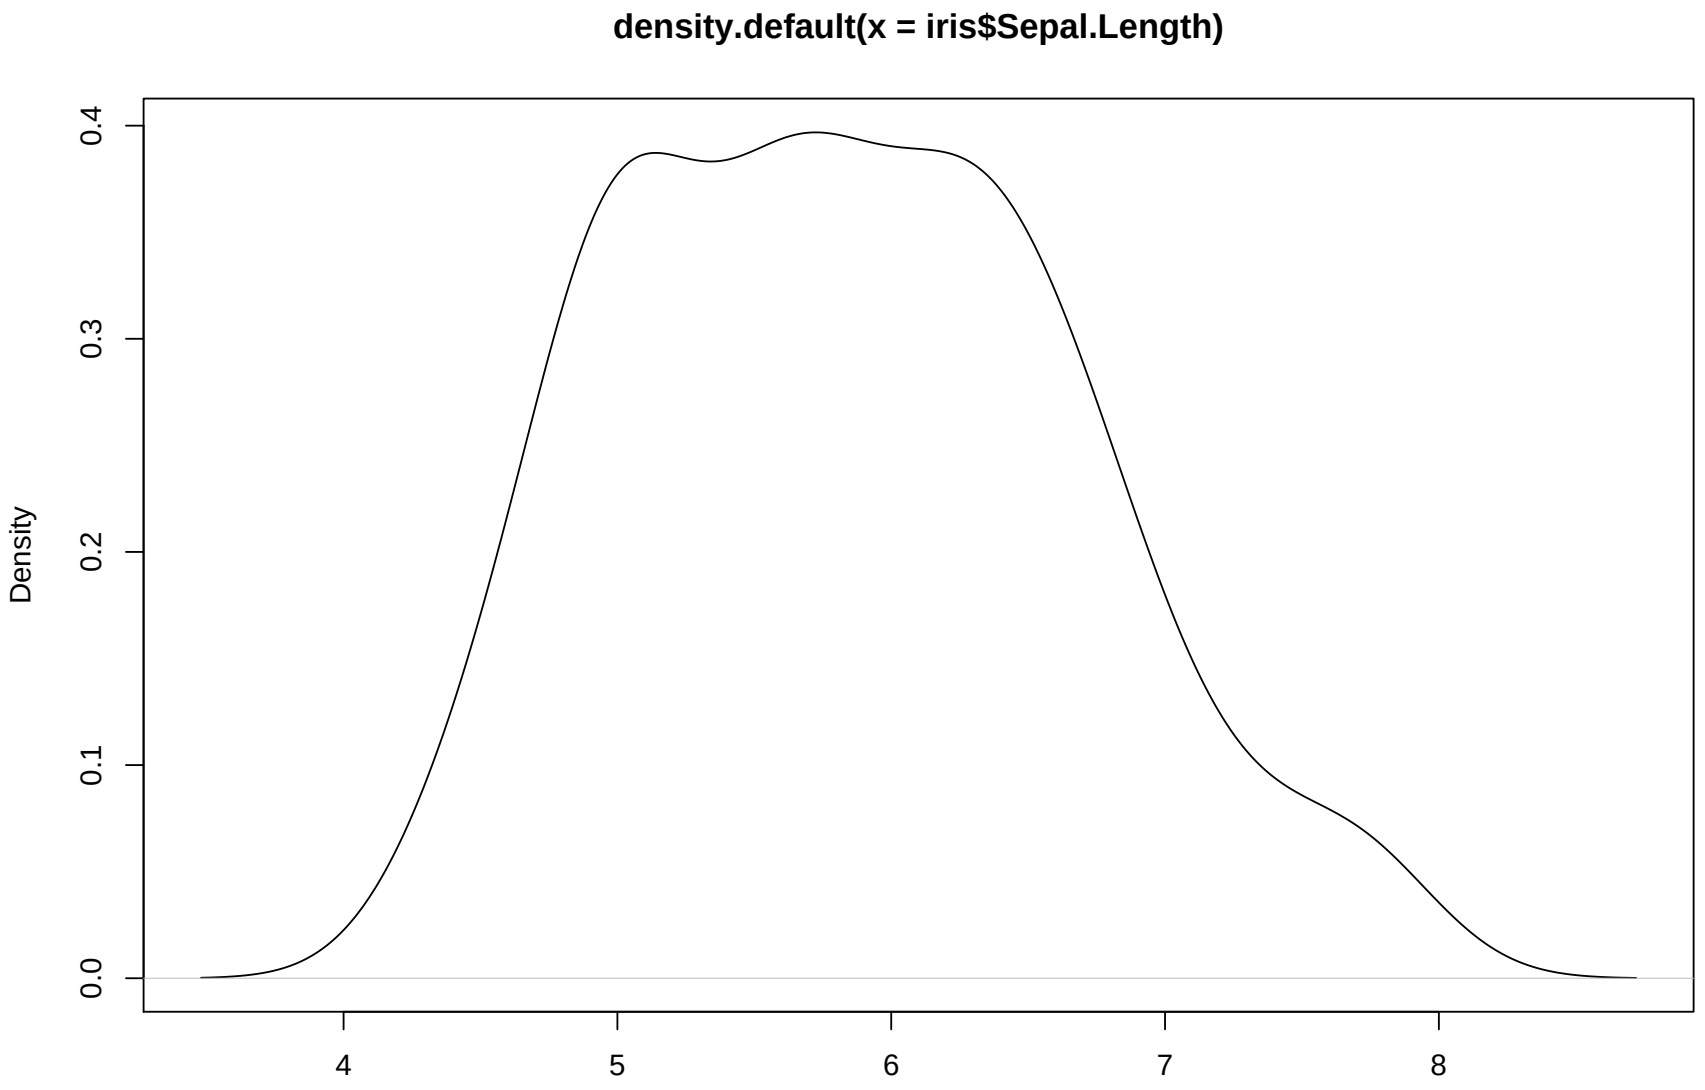

Errores como features:

El vocabulario internacional de metrologia (VIM) define una cantidad como **una propiedad de un fenomeno, cuerpo o substancia, donde la propiedad tiene una magnitud que puede ser expresada como un numero y una referencia**.

donde tipicamente el numero es el **valor de una cantidad** obtenida mediante un procedimiento de medicion, y la referencia es la **unidad de medicion**.

Adicionalmente, toda cantidad debe tener asociada alguna indicacion sobre la calidad de la medicion, esto es un atributo cuantificable conocido como **incerteza o error**, que caracteriza que dispersion de valores que pueden ser atribuibles a una dada medicion.

Las incertezas pueden ser directamente medidas o derivadas en el caso de una medicion indirecta (Potencia=Voltaje*corriente) y deben obtenerse por propagacion. Ver las librerias units y errors en CRAN, para un uso adecuado de las mismas como features o cuando se generan nuevos.

Explorando multiples variables 1:

- 1 covariance of two variables

```
cov(iris$Sepal.Length, iris$Petal.Length)
```

```
## [1] 1.274315
```

- 2 Correlation of two variables

```
cor(iris$Sepal.Length, iris$Petal.Length)
```

```
## [1] 0.8717538
```

Explorando multiples variables 2:

- 3 Distribution in subsets

```
aggregate(Sepal.Length ~ Species, summary, data=iris)
```

```
##      Species Sepal.Length.Min. Sepal.Length.1st Qu. Sepa
## 1     setosa              4.300                 4.800
## 2 versicolor              4.900                 5.600
## 3  virginica              4.900                 6.225
##   Sepal.Length.Mean Sepal.Length.3rd Qu. Sepal.Length.Ma
## 1             5.006                 5.200             5.8
## 2             5.936                 6.300             7.0
## 3             6.588                 6.900             7.9
```

Explorando multiples variables 3:

- 4 Box Plot

```
boxplot(Sepal.Length~Species, data=iris)
```

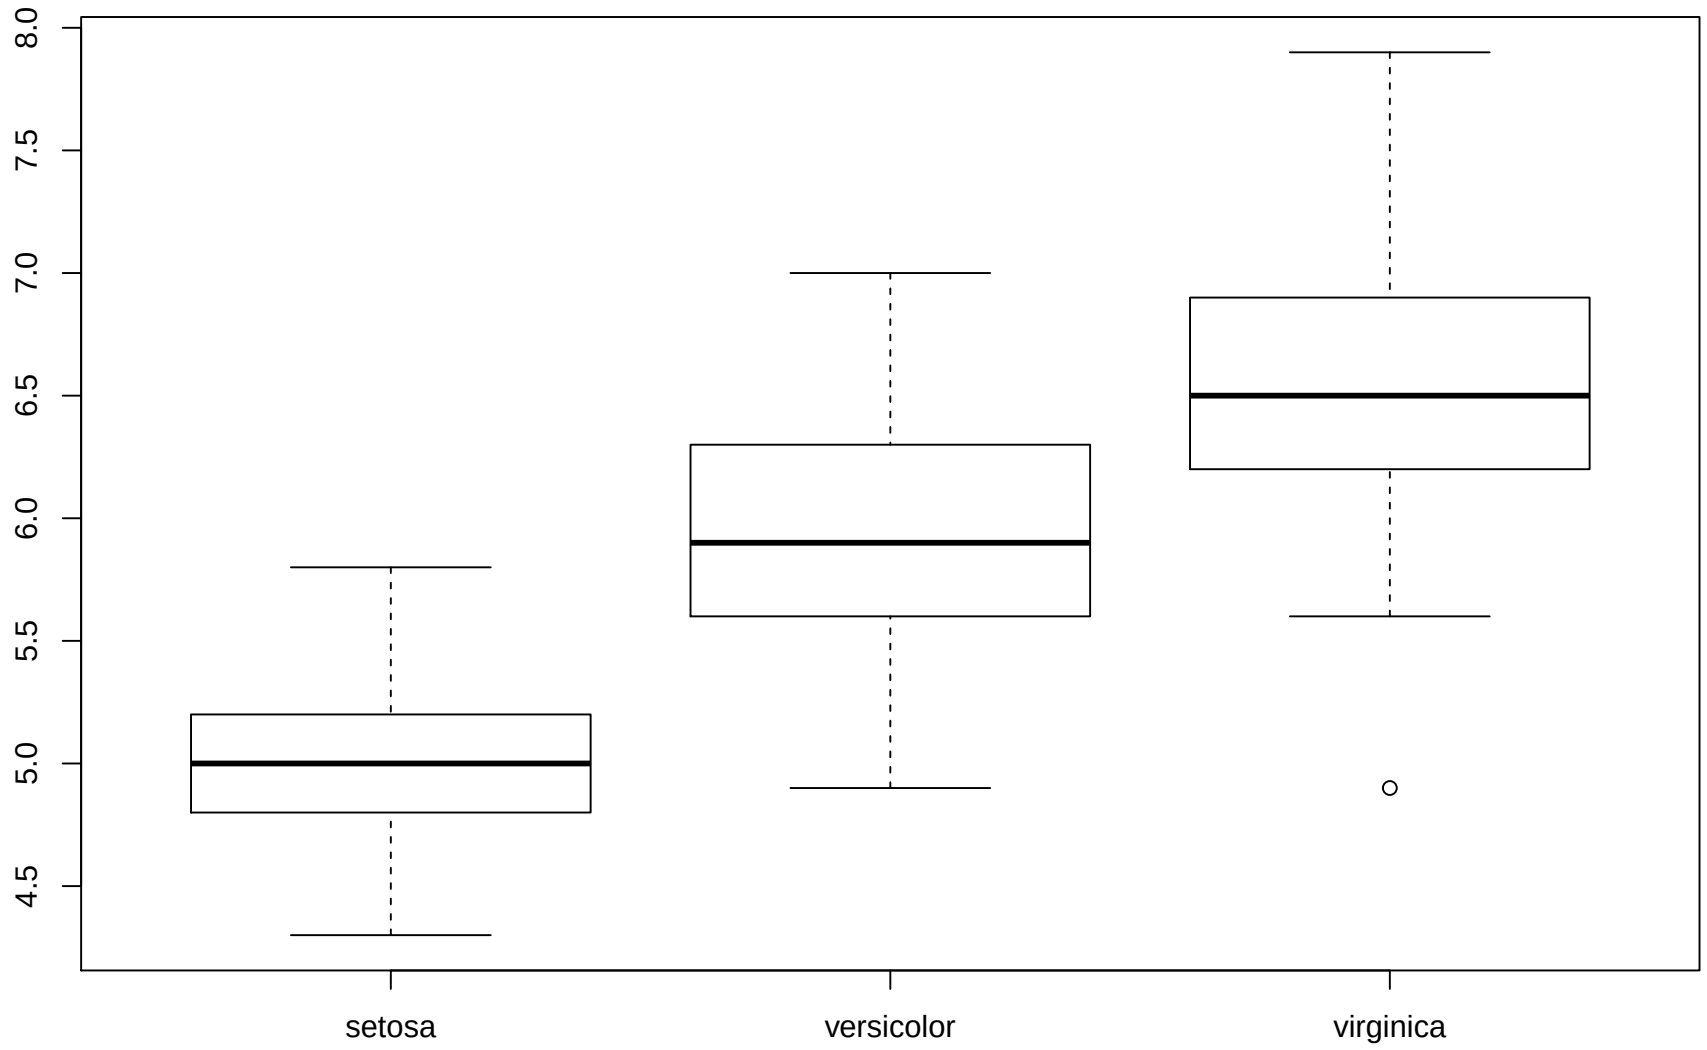

Explorando multiples variables 4:

- 5 Scatter plot

```
plot(iris$Sepal.Length, iris$Sepal.Width)
```

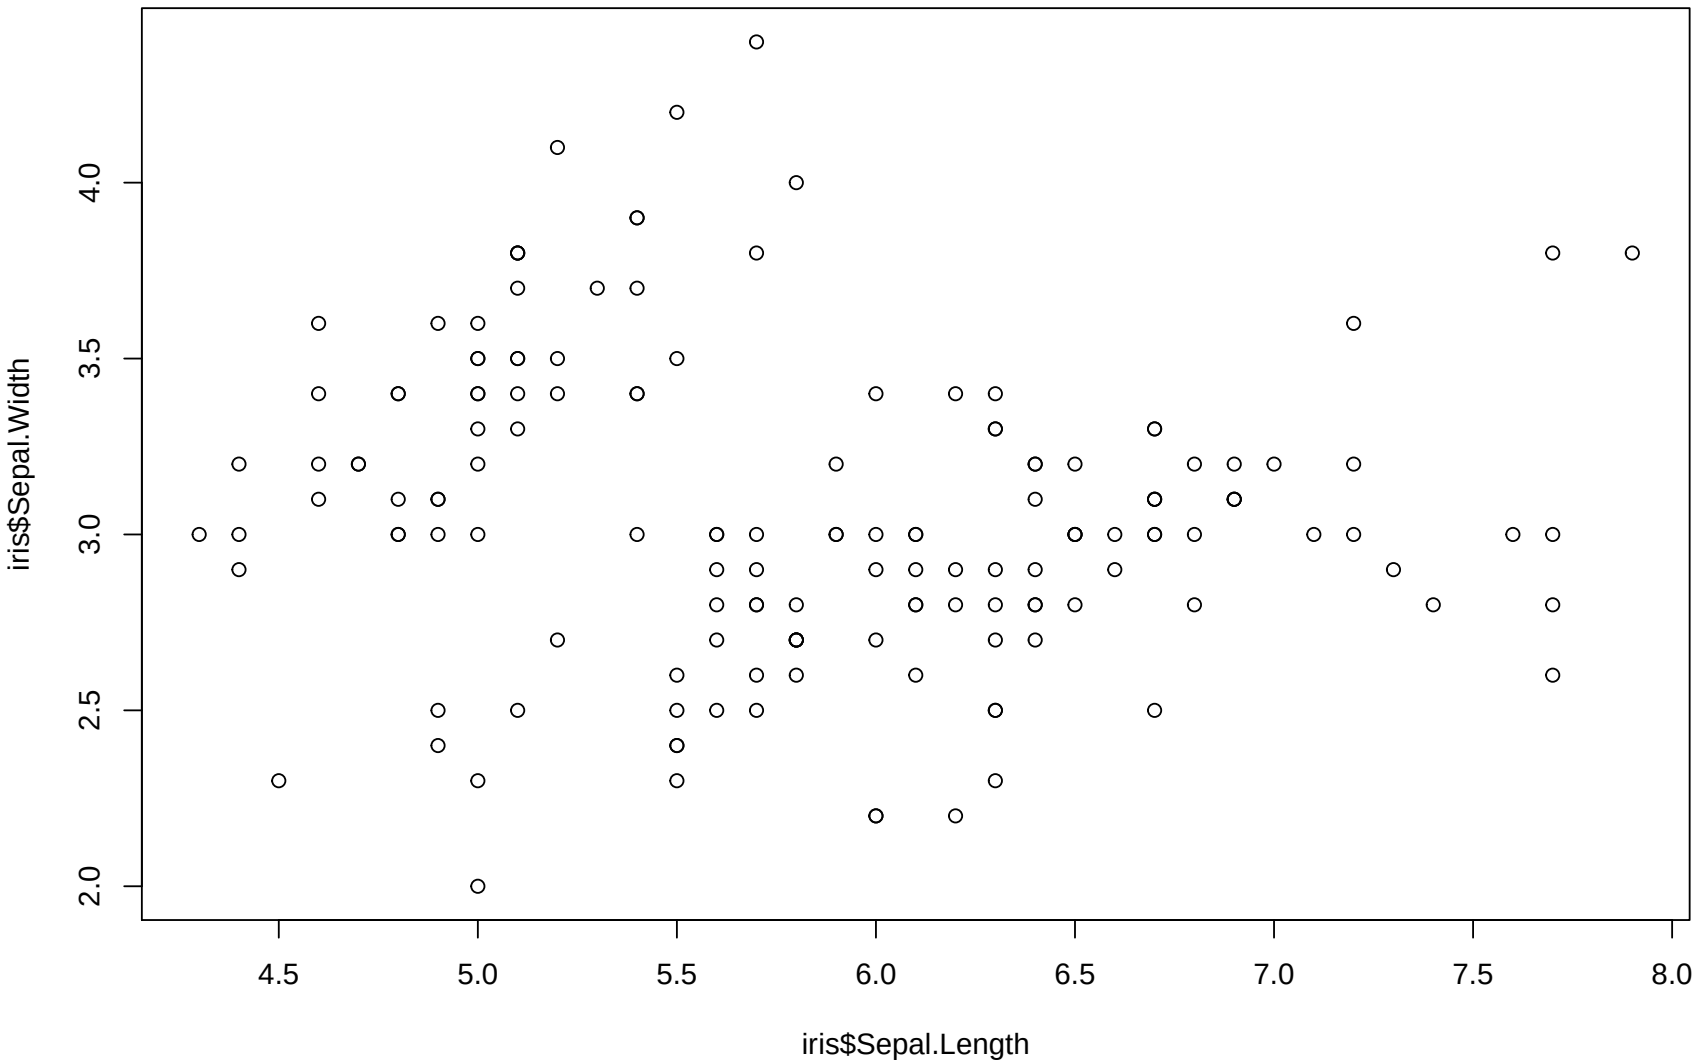

Explorando multiples variables 5:

- 6 Pairs plot

```
pairs(iris)
```

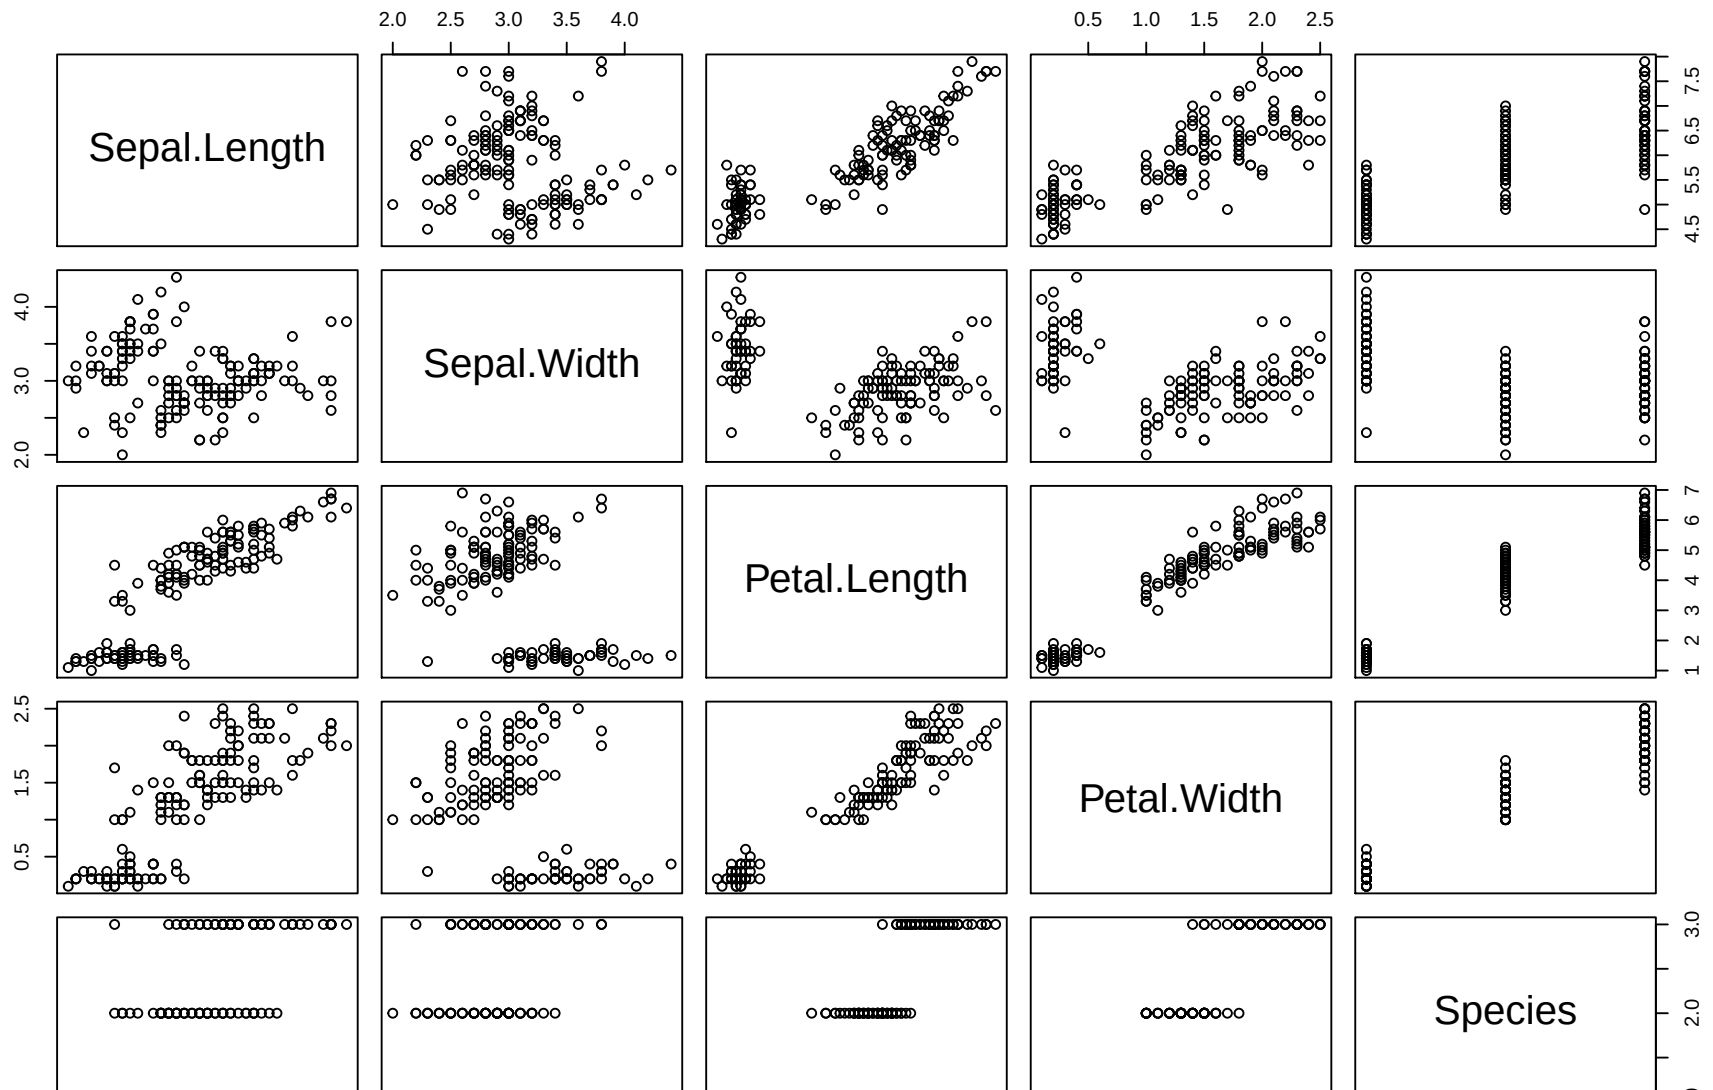

Explorando multiples variables 6:

- 7 other complicated plots

```
library(lattice)
splom(~iris[1:3] | Species, data = iris, pscales = 0,varnam
```

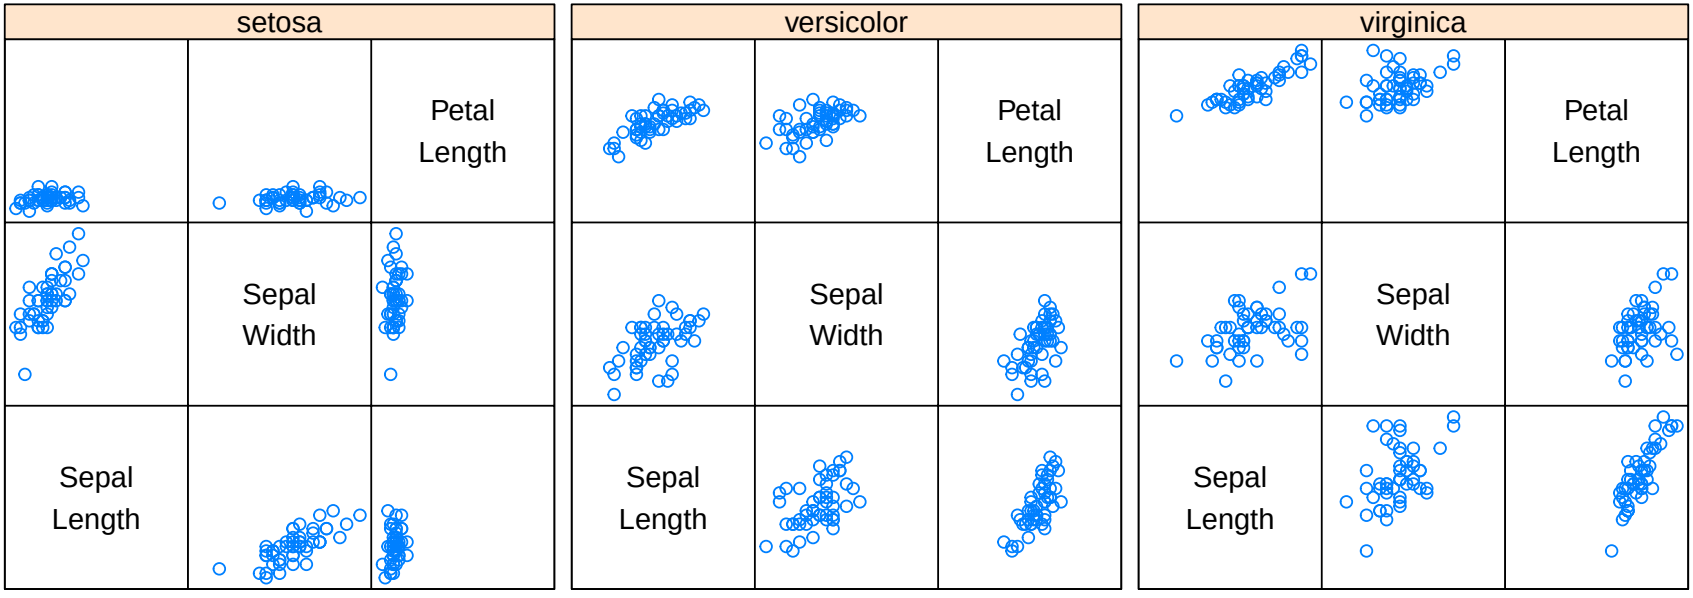

Scatter Plot Matrix

Explorando multiples variables 7:

```
parallel(~iris[, 1:4] | Species, data = iris, layout = c(3,
```

```
## Warning: 'parallel' is deprecated.
## Use 'parallelplot' instead.
## See help("Deprecated")
```

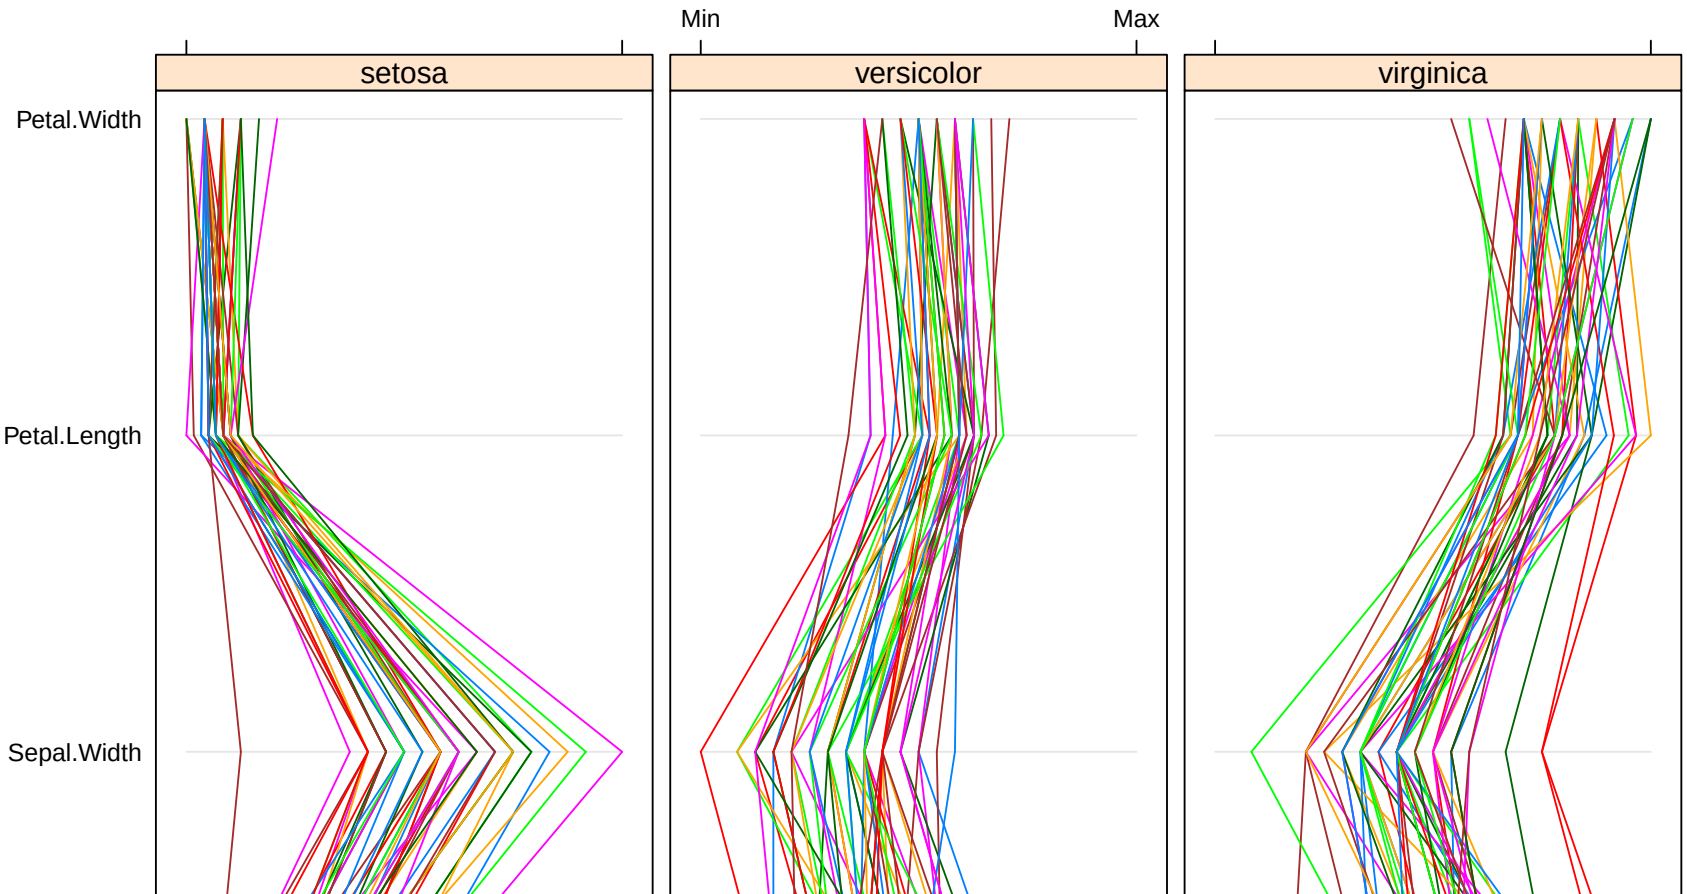

More Exploration

- Level Plot

```
library(lattice)
print(levelplot(Petal.Width~Sepal.Length*Sepal.Width, iris
```

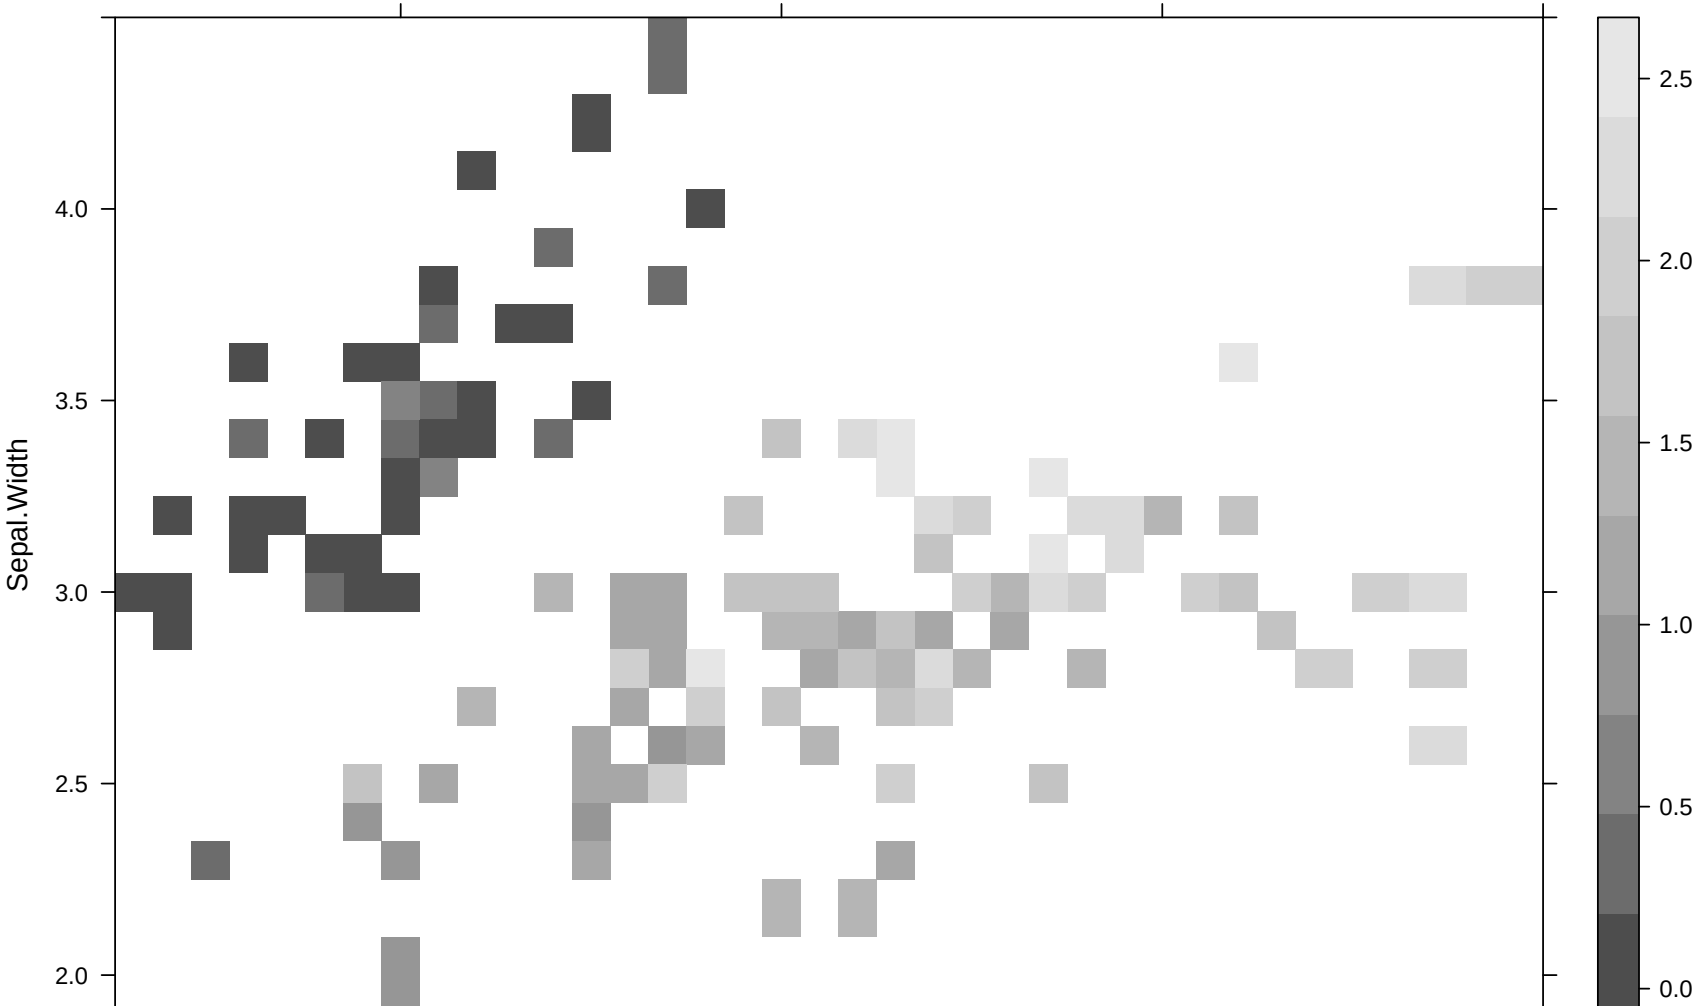

More Exploration

- Contour

```
filled.contour(volcano, color = terrain.colors, asp = 1, pl
```

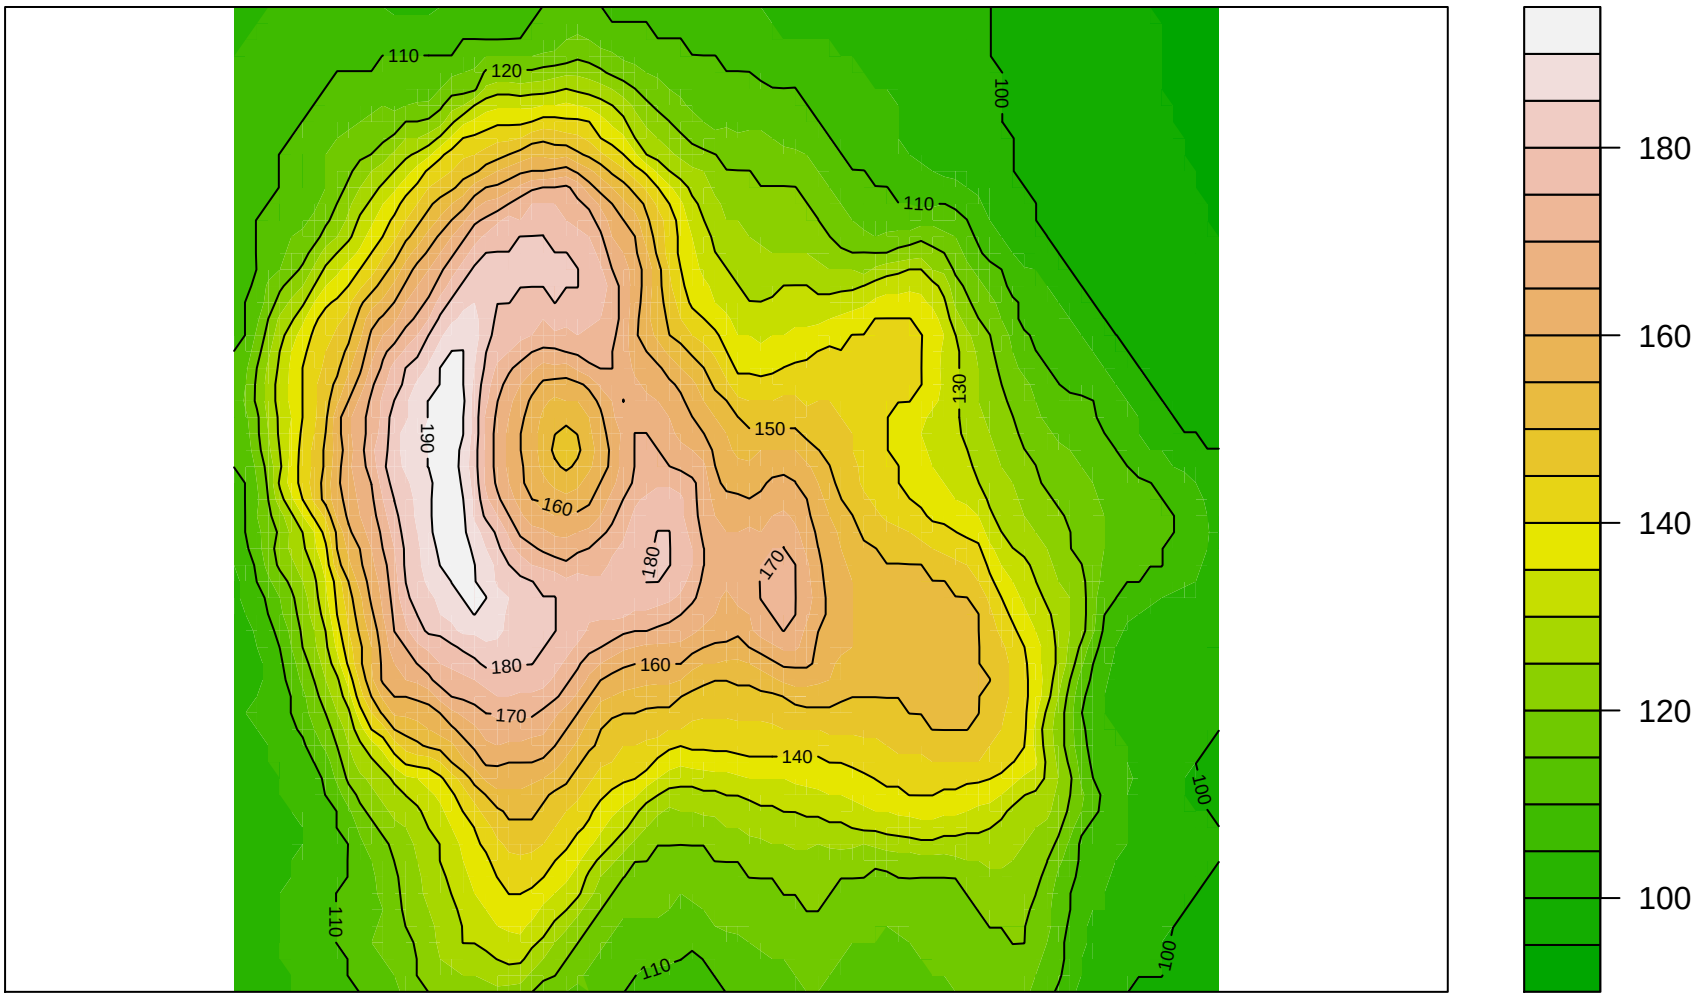

More Exploration

- 3D Surface

```
persp(volcano, theta = 25, phi = 30, expand = 0.5, col = "
```

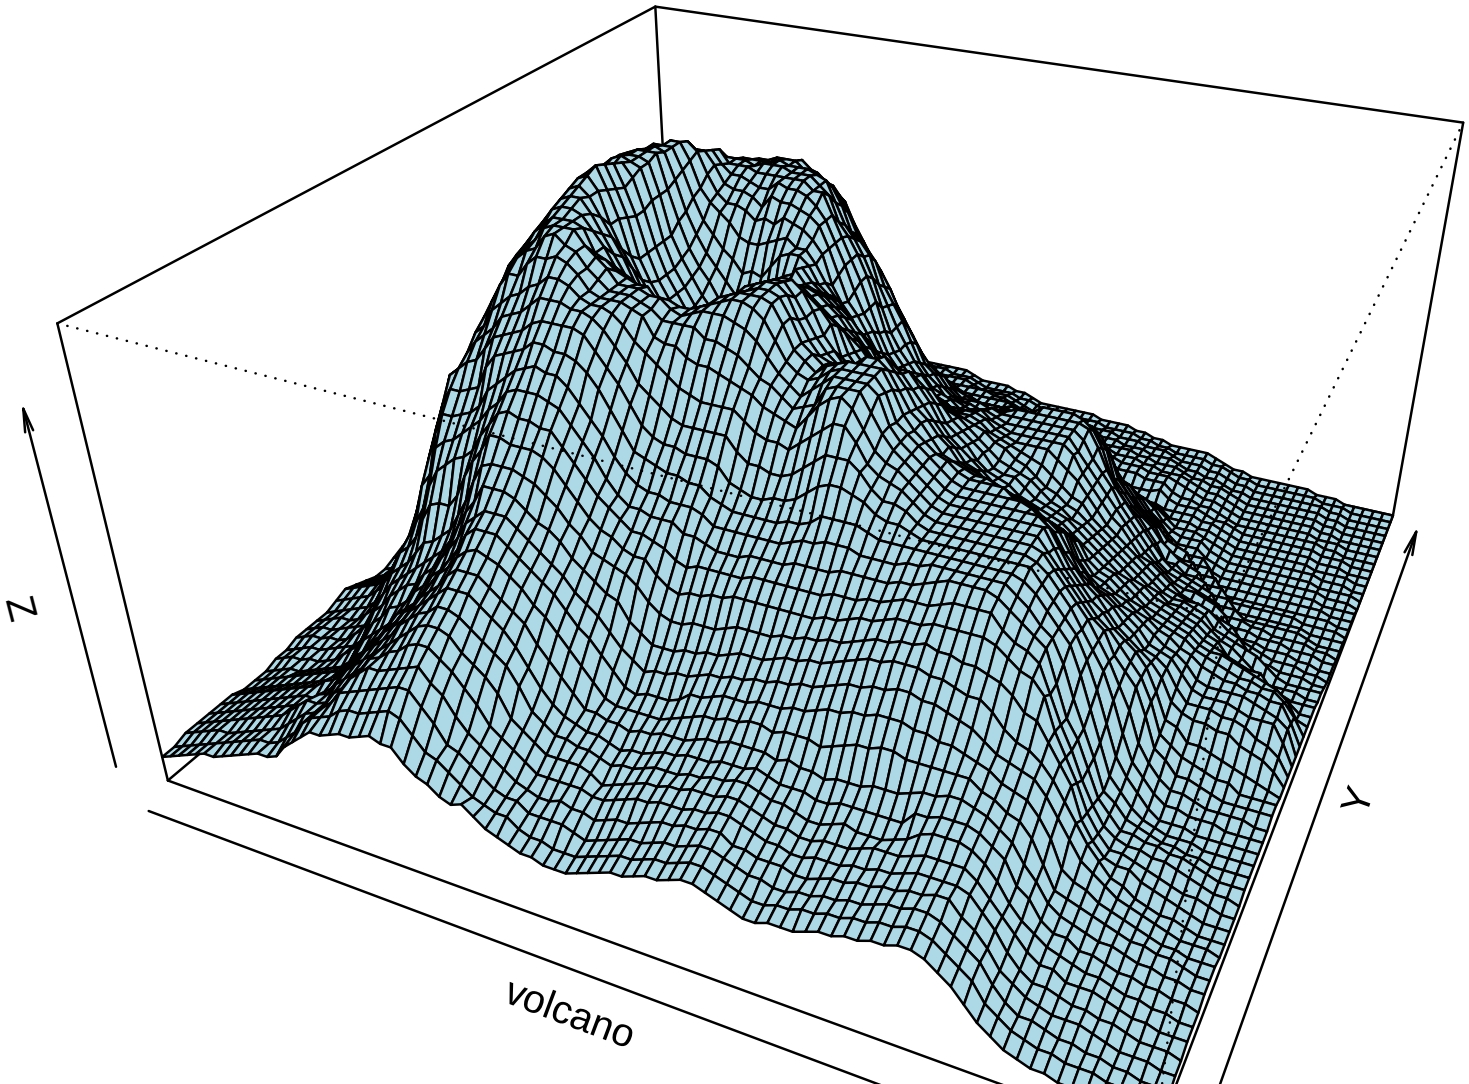

More Exploration

- Interactive 3D Scatter Plot

```
library(rgl)
```

```
## Warning in rgl.init(initValue, onlyNULL): RGL: unable to
```

```
## Warning: 'rgl_init' failed, running with rgl.useNULL = T
```

```
plot3d(iris$Petal.Width, iris$Sepal.Length, iris$Sepal.Widt
```

Writing plots as pdf/ps.

- Save as a .PDF file

```
pdf("myPlot.pdf")
x <- 1:50
plot(x, log(x))
graphics.off()
```

- Save as a postscript file

```
postscript("myPlot.ps")
x <- -20:20
plot(x, x^2)
graphics.off()
```

Writing plots as png/jpeg

- Find temp.. or save as png or jpg

```
jpeg("plot.jpg")
plot(x, 1/x)
dev.off()
```

```
## pdf
##   2
```

Ejercicios:

Visualizacion es una herramienta muy importante para la generacion de intuicion, pero raramente uno tiene los datos en la forma necesaria. Frecuentemente se necesitara crear nuevas variables o simplemente reordenarlas.

Exploraremos ahora la manipulacion basica utilizando un conjunto de datos sobre los vuelos en Nueva York en 2013.

```
library(nycflights13)
fligths<-nycflights13::flights
fligths
```

```
## # A tibble: 336,776 x 19
##      year month   day dep_time sched_dep_time dep_delay a
##     <int> <int> <int>    <int>          <int>     <dbl>
##  1  2013     1     1      517            515         2
##  2  2013     1     1      533            529         4
##  3  2013     1     1      542            540         2
##  4  2013     1     1      544            545        -1
```

Practico 1: Entregar un Rmd donde se encuentren todos los vuelos que:

- Que arribaron con un retraso de mas de dos horas.
- Volaron hacia Houston (IAH o HOU)
- Fueron operados por United, American o Delta.
- Salieron en Verano (Julio, Agosto y Septiembre)
- Arrivaron mas de dos horas tarde, pero salieron bien.
- Salieron entre medianoche y las 6 am.